

Relatório de Ética e Governança em Visão Computacional

Análise de Vieses e Fairness na Classificação de Imagens Médicas

1. Introdução

Nesse trabalho foi desenvolvido um protótipo de classificação de imagens médicas utilizando Redes Neurais Convolucionais (CNN) e Transfer Learning com MobileNetV2. Além do desempenho preditivo, é importante avaliar possíveis vieses presentes no conjunto de dados e seus impactos éticos, especialmente em aplicações da área da saúde, onde decisões incorretas podem afetar diretamente pacientes e profissionais médicos.


2. Limitações do Dataset

O dataset utilizado contém imagens de raio-X de tórax classificadas em duas categorias: Normal e Pneumonia.

2.1 Desbalanceamento das Classes

Foi identificado um desbalanceamento significativo entre as classes:

Havendo 1.341 imagens de raio-X com classificação normal, representando 25,71% das imagens de treino. E 3.875 imagens de raio-X com classificação pneumonia, representando os 74,29% restantes




Esse desbalanceamento pode induzir o modelo a favorecer a classe majoritária pneumonia, resultando em maior número de falsos positivos ou desempenho inferior para pacientes saudáveis.

Para reduzir esse problema foi utilizada a técnica de Class Weight durante o treinamento, atribuindo maior peso à classe minoritária.

2.2 Representatividade Limitada

O dataset utilizado do site <https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia> não fornece informações detalhadas sobre:

- Faixa etária dos pacientes;
- Sexo dos pacientes;
- Etnia ou origem populacional;
- Equipamentos utilizados na aquisição das imagens;



A ausência dessas informações dificulta a avaliação de possíveis desigualdades de desempenho entre grupos populacionais.

O dataset apenas descreve as seguintes informações referentes a captação das imagens:

“Radiografias de tórax (ântero-posterior) foram selecionadas de coortes retrospectivas de pacientes pediátricos de um a cinco anos de idade do Centro Médico Infantil e da Mulher de Guangzhou. Todos os exames de raio-X de tórax foram realizados como parte do atendimento clínico de rotina dos pacientes.

Para a análise das radiografias de tórax, todas as imagens foram inicialmente submetidas a um controle de qualidade, com a remoção de exames de baixa qualidade ou ilegíveis. Os diagnósticos das imagens foram então classificados por dois médicos especialistas

antes de serem liberados para o treinamento do sistema de IA. Para corrigir eventuais erros de classificação, o conjunto de avaliação também foi verificado por um terceiro especialista.”

2.3 Generalização

Como as imagens foram coletadas em contextos específicos, o modelo pode apresentar desempenho inferior quando aplicado a hospitais, equipamentos ou populações diferentes dos presentes no conjunto de treinamento.

3. Avaliação de Fairness

Como o dataset não possui atributos demográficos disponíveis, não foi possível calcular métricas clássicas de fairness entre grupos protegidos, como sexo, idade ou etnia.

Entretanto, foi realizada uma análise indireta utilizando métricas por classe.

Resultados dos Modelos

Modelo	Acurácia	Precision	Recall	F1-Score
CNN	62,34%	62,44%	99,74%	76,80%
MobileNetV2	87,34%	93,80%	85,38%	89,40%

Observou-se que a CNN apresentou recall extremamente elevado para a classe pneumonia, indicando tendência a classificar grande parte das imagens como positivas. Esse comportamento pode ser interpretado como um efeito indireto do desbalanceamento do dataset.

Já o modelo MobileNetV2 apresentou melhor equilíbrio entre precisão e recall, reduzindo a quantidade de classificações incorretas.

Métrica de Paridade Demográfica

A paridade demográfica exige que a proporção de previsões positivas seja semelhante entre diferentes grupos populacionais.

Como não há informações demográficas disponíveis no dataset, essa métrica não pôde ser calculada diretamente. Essa limitação evidencia a importância da coleta de atributos demográficos em projetos de Inteligência Artificial aplicada à saúde.

Métrica de Equal Opportunity

A equal opportunity avalia se diferentes grupos apresentam taxas semelhantes de verdadeiros positivos (Recall).

Novamente, devido à ausência de informações sobre grupos protegidos, não foi possível realizar essa análise. Portanto, não é possível garantir que o sistema apresente desempenho equivalente para diferentes populações.

4. Implicações Éticas

Modelos de IA aplicados à saúde devem ser utilizados somente como sistemas de apoio para decisão, não substituindo a avaliação médica.

Entre os principais riscos estão:

- Diagnósticos incorretos devido a limitações do conjunto de dados;
- Possíveis desigualdades de desempenho entre grupos populacionais;
- Redução da confiabilidade do sistema quando utilizado em ambientes diferentes daqueles presentes durante o treinamento;
- Impactos causados por falsos positivos ou falsos negativos.

Por esse motivo, recomenda-se que qualquer resultado produzido pelo modelo seja sempre validado por profissionais da área médica.

5. Estratégias de Mitigação

Para reduzir riscos de viés e melhorar a confiabilidade do sistema, recomenda-se:

- Utilizar datasets mais balanceados;
- Incorporar dados de múltiplos hospitais e equipamentos;
- Coletar atributos demográficos de forma ética e anonimizada;
- Monitorar métricas de fairness por grupo populacional;
- Realizar validação externa em novos conjuntos de dados;
- Manter supervisão humana nas decisões clínicas.

6. Conclusão

A principal limitação identificada no dataset foi o desbalanceamento entre as classes normal e pneumonia, além da ausência de informações demográficas que permitiriam uma avaliação completa de fairness. Embora técnicas de balanceamento tenham sido aplicadas durante o treinamento, não é possível assegurar que o modelo apresente desempenho equitativo para diferentes grupos populacionais. Dessa forma, recomenda-se cautela na utilização prática do sistema e a adoção de estratégias adicionais de mitigação de viés em futuras versões do projeto.